人脸图像性别分类

本实验将训练一个神经网络模型，对男女人脸图像进行性别分类。

本实验使用了 tf.keras，它是 TensorFlow 中用来构建和训练模型的高级 API。

导入需要用到的库

名称	版本	用途
Tensorflow	2.3.1	深度学习框架
Keras	2.4.3	基于Tensorflow的实现
scikit-learn	0.32.2	机器学习库
matplotlib	3.3.2	绘图库
pandas	1.1.3	数据处理库
numpy	1.19.2	矩阵库
opencv-Python	4.4.0.44	读取图片

```
# TensorFlow
import tensorflow as tf
from tensorflow import keras
from sklearn.model_selection import train_test_split
import matplotlib.pyplot as plt

# Helper libraries
from pandas import read_csv
import numpy as np
import pandas as pd
import cv2
import random

print(tf.__version__)
```

```
2.3.1
```

导入训练集和预处理数据

本实验使用 UTKFace 中的部分数据作为数据集，包括18000张包含标签的图片作为训练集，剩余 5708张图片作为测试集。

我们首先使用一个空白的列表用于存储图片，设定图片压缩后的长宽为100，指定训练集图片的路径。

注： Windows下遍历文件名的方式并不是按照 **"1.jpg、2.jpg、3.jpg、4.jpg、5.jpg..."** 从小到大的自然顺序， 而是按照 **"1.jpg、10.jpg、100.jpg、1000.jpg、10000.jpg、10001.jpg"** 的顺序。 因此如果直接使用os库中遍历文件夹下所有文件路径的方法，会导致图片与标签对应错误。所以我们最好的方式是使用循环 ，再通过拼接字符串的方式 *(.jpg)* 得到完整的文件名。

由于opencv读取图片是按照**BGR**通道进行读取的，我们需要转换成**RGB**才能得到正常的图片。再将每张图片除以255.0进行**归一化处理**。然后将图片压缩到指定的大小，并把所有图片放进一个列表中。

为了检验我们的操作结果，需要进行**数据可视化**。使用matplotlib库，创建一个图框，随机显示读取到的一张图片。

```
dataframe = read_csv('train.csv')
array_of_img = []  # this if for store all of the image data
image_size = 100
directory_name = "train/train/"
for i in dataframe.values[:, 0]:
    # print(filename) #just for test
    # img is used to store the image data
    # img = cv2.imread(directory_name + str(i) + ".jpg", cv2.IMREAD_GRAYSCALE)
    img = cv2.imread(directory_name + str(i) + ".jpg")
    # img = cv2.cvtColor(img, cv2.COLOR_BGR2RGB) #change channels from BGR to RGB
    img = img / 255.0
    img = cv2.resize(img, (image_size, image_size))
    array_of_img.append(img)
train_images = np.array(array_of_img)
array_of_img = []

# train_images = train_images.reshape(train_images.shape[0], image_size, image_size, 1)
# train_images = train_images.astype('float32')
sample = random.randint(0, 17992)
plt.figure()
plt.imshow(train_images[sample][:,:,::-1])
plt.colorbar()
plt.grid(False)
plt.show()
```

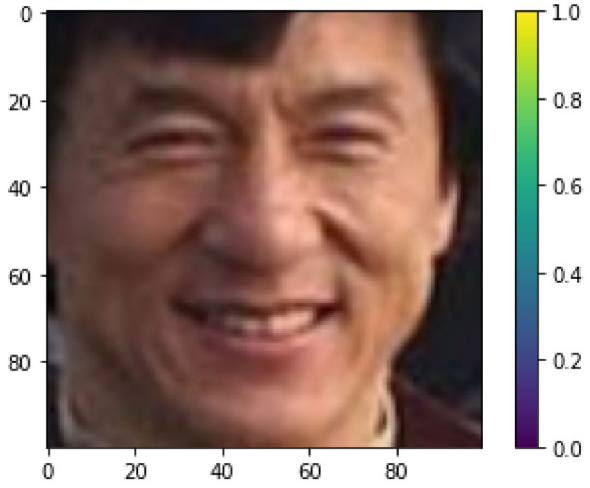

读取csv

使用pandas库中的read_csv方法读取train.csv文件,并显示出其中前10行数据。其中标签0表示男，1表示女。

```
dataframe.head(10)
```

	id	label
0	1	0
1	2	0
2	3	1
3	4	1
4	5	1
5	6	1
6	7	1
7	8	1
8	9	1
9	10	0

在这里我们仅需要标识男女的0、1标签，因此取数据的第一列。 为了压缩空间，将默认保存的int64类型转换为int8类型进行保存。最后释放掉不需要的dataframe和array变量。

```
array = dataframe.values
train_labels = np.array(array[:, 1], dtype='int8')
del dataframe
del array
```

数据增强

创建一个数据增强层，使用keras中的顺序模型来创建，其中包括五层，分别是：

1. 高斯噪声
2. 随机翻转（水平）
3. 随机变形
4. 随机旋转
5. 随机缩放

```
data_augmentation = keras.Sequential(
    [
        keras.layers.GaussianNoise(0.1, input_shape=(image_size, image_size, 3)),
        keras.layers.experimental.preprocessing.RandomFlip("horizontal"),
        keras.layers.experimental.preprocessing.RandomTranslation(0.1, 0.1),
        keras.layers.experimental.preprocessing.RandomRotation(0.1),
        keras.layers.experimental.preprocessing.RandomZoom(0.1),
    ]
)
```

现在我们显示经过数据增强后的刚才那张图片:

```
plt.figure(figsize=(10, 10))
for i in range(9):
    temp = train_images[sample:sample+1]
    augmented_images = data_augmentation(temp)
    ax = plt.subplot(3, 3, i + 1)
    plt.grid(False)
    plt.xticks([])
    plt.yticks([])
    plt.imshow(augmented_images[0][:,:,::-1])
```

加载数据集会返回四个 NumPy 数组：

- `train_images` 和 `train_labels` 数组是*训练集*，即模型用于学习的数据。
- `test_images` 和 `test_labels` 数组是*测试集*、会被用来对模型进行测试。

图像是 100x100 的 NumPy 数组，像素值介于 0 到 1 之间。*标签*是整数数组，介于 0 到 1 之间。这些标签对应于图像所代表的性别*类*：

标签	类别
0	男性
1	女性

每个图像都会被映射到一个标签。由于数据集不包括　　，所以将它们存储在下方，供稍后绘制图像时使用：

```
7  class_names = ['male', 'female']
```

浏览数据

在训练模型之前，我们先浏览一下数据集的格式。以下代码显示训练集中有 17993（去除7张非人脸图片）个图像，每个图像由 100 x 100 的像素表示，包含3个通道：

```
8  train_images.shape
```

```
8  (17993, 100, 100, 3)
```

同样，训练集中有 17993 个标签：

```
9  len(train_labels)
```

```
9  17993
```

每个标签都是一个 *0或1* 的整数：

```
10 train_labels
```

```
10 array([0, 0, 1, ..., 1, 1, 1], dtype=int8)
```

为了验证数据的格式是否正确，以及您是否已准备好构建和训练网络，让我们显示 *训练集*中的随机 25 个图像，并在每个图像下方显示类名称。

```
11 plt.figure(figsize=(10,10))
   for i in range(25):
       plt.subplot(5,5,i+1)
       plt.xticks([])
       plt.yticks([])
       plt.grid(False)
       sample = random.randint(0, 17992)
       plt.imshow(train_images[sample][:,:,::-1])
       plt.xlabel(class_names[train_labels[sample]])
   plt.show()
```

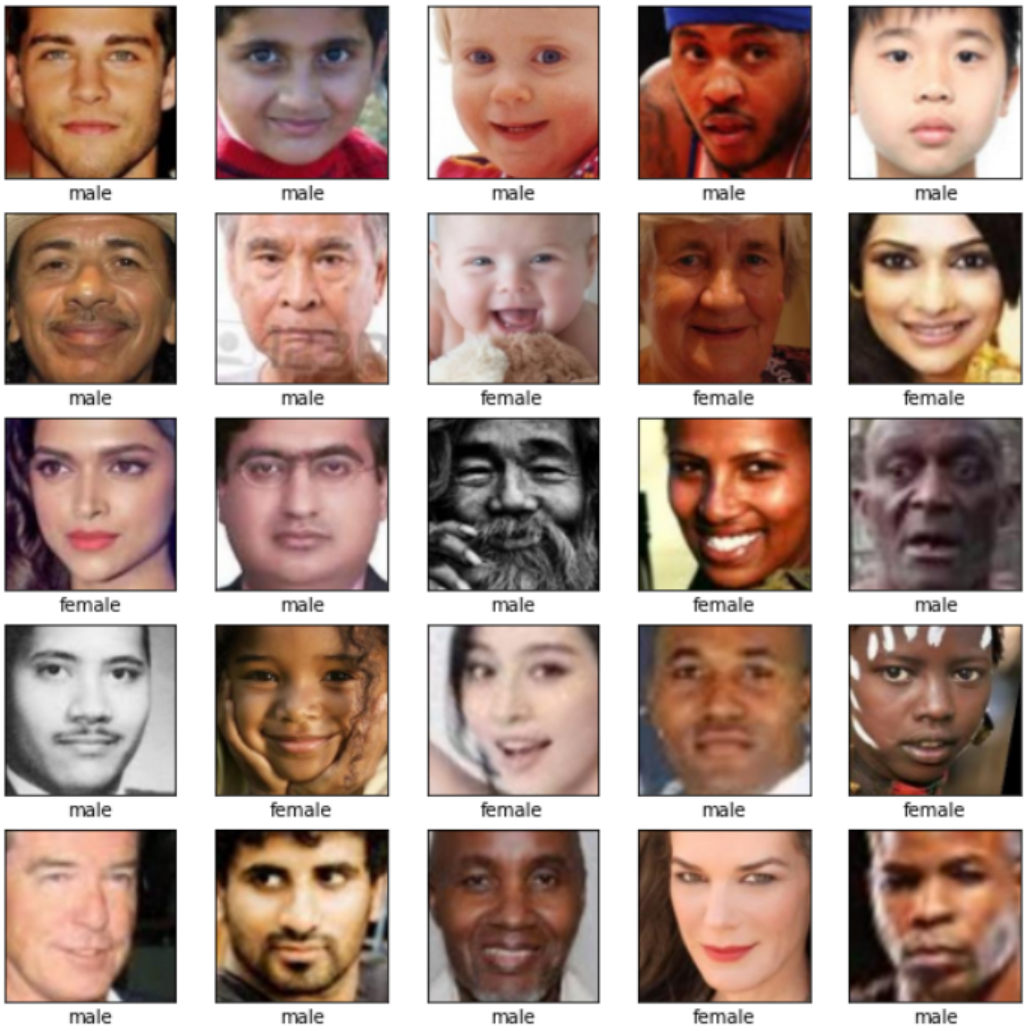

构建模型

构建神经网络需要先配置模型的层，然后再编译模型。

设置层

神经网络的基本组成部分是*层*。层会从向其馈送的数据中提取表示形式。希望这些表示形式有助于解决手头上的问题。

大多数深度学习都包括将简单的层链接在一起。大多数层（如 `tf.keras.layers.Dense` ）都具有在训练期间才会学习的参数。

```
model = keras.Sequential([
    data_augmentation,
    keras.layers.Conv2D(25, kernel_size=(3, 3), padding='same', activation='relu'),
    keras.layers.Conv2D(50, kernel_size=(3, 3), padding='same', activation='relu'),
    keras.layers.BatchNormalization(),
    keras.layers.MaxPooling2D(),
    keras.layers.Dropout(0.2),
    keras.layers.Conv2D(50, kernel_size=(3, 3), padding='same', activation='relu'),
    keras.layers.Conv2D(100, kernel_size=(3, 3), padding='same', activation='relu'),
    keras.layers.BatchNormalization(),
```

```
    keras.layers.MaxPooling2D(),
    keras.layers.Dropout(0.2),
    keras.layers.Conv2D(100, kernel_size=(3, 3), padding='same', activation='relu'),
    keras.layers.Conv2D(200, kernel_size=(3, 3), padding='same', activation='relu'),
    keras.layers.BatchNormalization(),
    keras.layers.MaxPooling2D(),
    keras.layers.Dropout(0.2),
    keras.layers.Flatten(),
    keras.layers.Dense(50, activation='relu'),
    keras.layers.BatchNormalization(),
    keras.layers.Dropout(0.2),
    keras.layers.Dense(100, activation='relu'),
    keras.layers.BatchNormalization(),
    keras.layers.Dense(200, activation='relu'),
    keras.layers.BatchNormalization(),
    keras.layers.Dropout(0.2),
    keras.layers.Dense(2, activation='softmax')
])
```

首先是我们刚才定义的 数据增强层 ，然后是两个的相连的 卷积层 ，神经元分别为25和50，卷积核大小均为3x3； 再加上 批次标准化层 、 最大池化层 和失活率为0.2的 Dropout层 ； 以同样的方式再添加两遍和上述相同的层，只不过卷积层的神经元个数分别为50、100、100和200； 完成所有的卷积操作后，便来到了 展平层 ，将最后一个卷积层的输出12x12x200展平成28800x1； 随后我们添加3个 全连接层 ，神经元个数分别为50、100和200，并在它们之间插入 批次标准化层 和失活率为0.2的 Dropout层 ； 最后的 输出层 不变仍为两个神经元，用Softmax函数优化，而 卷积层 均用ReLu函数优化。

编译模型

在准备对模型进行训练之前，还需要再对其进行一些设置。以下内容是在模型的*编译*步骤中添加的：

- *损失函数* - 用于测量模型在训练期间的准确率。希望最小化此函数，以便将模型"引导"到正确的方向上。
- *优化器* - 决定模型如何根据其看到的数据和自身的损失函数进行更新。
- *指标* - 用于监控训练和测试步骤。以下示例使用了*准确率*，即被正确分类的图像的比率。

```
13 model.compile(optimizer='adam',
                 loss=tf.keras.losses.SparseCategoricalCrossentropy(),
                 metrics=['accuracy']
                 )
   model.summary()
```

```
Model: "sequential_1"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
sequential (Sequential)      (None, 100, 100, 3)       0
_________________________________________________________________
conv2d (Conv2D)              (None, 100, 100, 25)      700
_________________________________________________________________
conv2d_1 (Conv2D)            (None, 100, 100, 50)      11300
_________________________________________________________________
batch_normalization (BatchNo (None, 100, 100, 50)      200
_________________________________________________________________
max_pooling2d (MaxPooling2D) (None, 50, 50, 50)        0
```

```
_________________________________________________________________
dropout (Dropout)            (None, 50, 50, 50)        0
_________________________________________________________________
conv2d_2 (Conv2D)            (None, 50, 50, 50)        22550
_________________________________________________________________
conv2d_3 (Conv2D)            (None, 50, 50, 100)       45100
_________________________________________________________________
batch_normalization_1 (Batch (None, 50, 50, 100)       400
_________________________________________________________________
max_pooling2d_1 (MaxPooling2 (None, 25, 25, 100)       0
_________________________________________________________________
dropout_1 (Dropout)          (None, 25, 25, 100)       0
_________________________________________________________________
conv2d_4 (Conv2D)            (None, 25, 25, 100)       90100
_________________________________________________________________
conv2d_5 (Conv2D)            (None, 25, 25, 200)       180200
_________________________________________________________________
batch_normalization_2 (Batch (None, 25, 25, 200)       800
_________________________________________________________________
max_pooling2d_2 (MaxPooling2 (None, 12, 12, 200)       0
_________________________________________________________________
dropout_2 (Dropout)          (None, 12, 12, 200)       0
_________________________________________________________________
flatten (Flatten)            (None, 28800)             0
_________________________________________________________________
dense (Dense)                (None, 50)                1440050
_________________________________________________________________
batch_normalization_3 (Batch (None, 50)                200
_________________________________________________________________
dropout_3 (Dropout)          (None, 50)                0
_________________________________________________________________
dense_1 (Dense)              (None, 100)               5100
_________________________________________________________________
batch_normalization_4 (Batch (None, 100)               400
_________________________________________________________________
dense_2 (Dense)              (None, 200)               20200
_________________________________________________________________
batch_normalization_5 (Batch (None, 200)               800
_________________________________________________________________
dropout_4 (Dropout)          (None, 200)               0
_________________________________________________________________
dense_3 (Dense)              (None, 2)                 402
=================================================================
Total params: 1,818,502
Trainable params: 1,817,102
Non-trainable params: 1,400
_________________________________________________________________
```

训练模型

训练神经网络模型需要执行以下步骤：

1. 将训练数据馈送给模型。在本例中，训练数据位于 `train_images` 和 `train_labels` 数组中。
2. 模型学习将图像和标签关联起来。
3. 要求模型对测试集（在本例中为 `test_images` 数组）进行预测。

准备工作

使用scikit-learn库中的train_test_split从训练集中划分出*90%*的图片训练，而剩余*10%*的图片作为验证集实时跟踪训练的效果。

我们添加3个回调：

1. ModelCheckpoint：使用val_accuracy（验证集精度）是否提升作为指标，一旦有提升则立刻保存当前训练的权重，从而能在所有训练轮数中保存与验证集最贴切的模型；
2. ReduceLROnPlateau：使用val_loss（验证集误差）是否降低作为指标，如果在3个训练轮数后没有降低，则降低学习率0.0001，可以让模型更加容易接近局部最优减少震荡；
3. EarlyStopping：使用val_loss（验证集误差）是否降低作为指标，如果在50个训练轮数后没有降低，则立即停止训练，从而避免因模型拟合而造成不必要的资源浪费。

14
```
X_train, X_val, Y_train, Y_val = train_test_split(train_images, train_labels, test_size=0.1, random
del train_images
del train_labels

save_weights = 'save_weights.h5'
last_weights = 'last_weights.h5'
best_weights = 'best_weights.h5'
# model.load_weights(best_weights)

checkpoint = keras.callbacks.ModelCheckpoint(best_weights, monitor='val_accuracy', save_best_only=T
                                             verbose=1)
reduce = keras.callbacks.ReduceLROnPlateau(monitor='val_loss', factor=0.1, patience=3, verbose=0, m
                                           min_delta=0.0001, cooldown=0, min_lr=0)
earlyStopping = keras.callbacks.EarlyStopping(monitor='val_loss', patience=50, verbose=1, mode='aut
callbacks = [checkpoint]
```

向模型馈送数据

要开始训练，调用 `model.fit` 方法，这样命名是因为该方法会将模型与训练数据进行"拟合"，并将训练中的信息保存在 `hist` 中。 训练集为 `X_train` 、标签为 `Y_train` 、轮数为2000、验证集为 `X_val` 、标签为 `Y_val` 。

将最后一轮训练好的权重保存到 `last_weights` 中。

利用训练历史数据中的 训练集精度 、验证集精度 、 训练集损失 、 验证集损失 进行绘图。

由于篇幅的限制，这里只显示训练前10轮的结果。

15
```
# hist = model.fit(train_images, train_labels, epochs=2000)
hist = model.fit(X_train, Y_train, epochs=10, validation_data=(X_val, Y_val), use_multiprocessing=T
                 callbacks=callbacks, workers=3)

model.save_weights(last_weights)
plt.figure()

acc = hist.history['accuracy']
val_acc = hist.history['val_accuracy']
loss = hist.history['loss']
val_loss = hist.history['val_loss']

epochs = range(len(acc))

plt.plot(epochs, acc, 'r', label='Training acc')  # 'bo'为画蓝色圆点，不连线
plt.plot(epochs, val_acc, 'b', label='Validation acc')
plt.plot(epochs, loss, 'g', label='Training loss')
plt.plot(epochs, val_loss, 'y', label='Validation loss')
plt.title('Training and validation accuracy,Training and validation loss')
plt.legend()  # 绘制图例，默认在右上角
```

```
plt.show()

Epoch 1/10
507/507 [==============================] - ETA: 0s - loss: 0.7083 - accuracy: 0.6326 □□□□□□□□□□
Epoch 00001: val_accuracy improved from -inf to 0.71778, saving model to best_weights.h5
507/507 [==============================] - 27s 52ms/step - loss: 0.7083 - accuracy: 0.6326 - val_lo
Epoch 2/10
506/507 [==============================>.] - ETA: 0s - loss: 0.5550 - accuracy: 0.7220 □□□□□□□□□□
Epoch 00002: val_accuracy improved from 0.71778 to 0.75222, saving model to best_weights.h5
507/507 [==============================] - 24s 48ms/step - loss: 0.5550 - accuracy: 0.7219 - val_lo
Epoch 3/10
505/507 [==============================>.] - ETA: 0s - loss: 0.4814 - accuracy: 0.7689 □□□□□□□□□□
Epoch 00003: val_accuracy improved from 0.75222 to 0.81611, saving model to best_weights.h5
507/507 [==============================] - 22s 43ms/step - loss: 0.4814 - accuracy: 0.7690 - val_lo
Epoch 4/10
505/507 [==============================>.] - ETA: 0s - loss: 0.4405 - accuracy: 0.7889 □□□□□□□□□□
Epoch 00004: val_accuracy did not improve from 0.81611
507/507 [==============================] - 22s 43ms/step - loss: 0.4405 - accuracy: 0.7888 - val_lo
Epoch 5/10
505/507 [==============================>.] - ETA: 0s - loss: 0.4138 - accuracy: 0.8080 □□□□□□□□□□
Epoch 00005: val_accuracy improved from 0.81611 to 0.86333, saving model to best_weights.h5
507/507 [==============================] - 22s 43ms/step - loss: 0.4139 - accuracy: 0.8079 - val_lo
Epoch 6/10
507/507 [==============================] - ETA: 0s - loss: 0.3830 - accuracy: 0.8263 □□□□□□□□□□
Epoch 00006: val_accuracy did not improve from 0.86333
507/507 [==============================] - 22s 44ms/step - loss: 0.3830 - accuracy: 0.8263 - val_lo
Epoch 7/10
505/507 [==============================>.] - ETA: 0s - loss: 0.3678 - accuracy: 0.8317 □□□□□□□□□□
Epoch 00007: val_accuracy improved from 0.86333 to 0.87333, saving model to best_weights.h5
507/507 [==============================] - 22s 44ms/step - loss: 0.3683 - accuracy: 0.8316 - val_lo
Epoch 8/10
505/507 [==============================>.] - ETA: 0s - loss: 0.3574 - accuracy: 0.8366 □□□□□□□□□□
Epoch 00008: val_accuracy did not improve from 0.87333
507/507 [==============================] - 22s 44ms/step - loss: 0.3573 - accuracy: 0.8366 - val_lo
Epoch 9/10
505/507 [==============================>.] - ETA: 0s - loss: 0.3417 - accuracy: 0.8466 □□□□□□□□□□
Epoch 00009: val_accuracy improved from 0.87333 to 0.88444, saving model to best_weights.h5
507/507 [==============================] - 22s 44ms/step - loss: 0.3420 - accuracy: 0.8466 - val_lo
Epoch 10/10
506/507 [==============================>.] - ETA: 0s - loss: 0.3371 - accuracy: 0.8463 □□□□□□□□□□
Epoch 00010: val_accuracy did not improve from 0.88444
507/507 [==============================] - 23s 45ms/step - loss: 0.3371 - accuracy: 0.8462 - val_lo
```

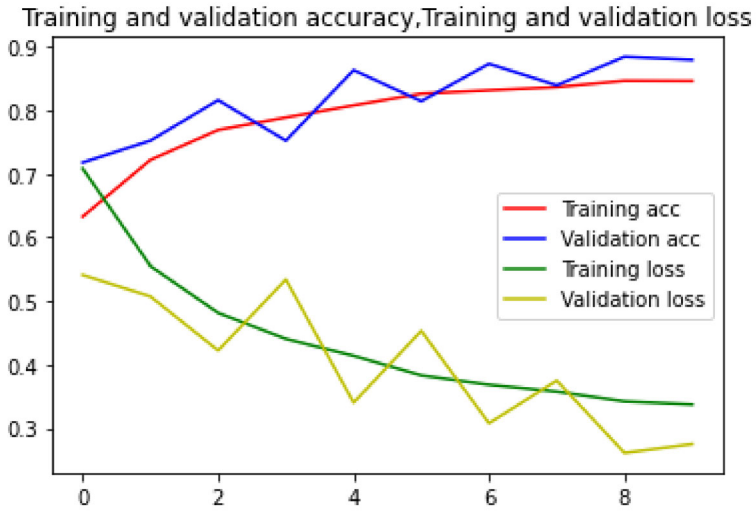

评估准确率

接下来，比较模型在测试数据集上的表现： 在模型训练期间，会显示损失和准确率指标。经过10轮的训练后，此模型在训练数据上的准确率达到了 0.8540（或 85.40%）左右。 结果

表明，模型在测试数据集上的准确率略低于训练数据集。训练准确率和测试准确率之间的差距代表*过拟合*。过拟合是指机器学习模型在新的、以前未曾见过的输入上的表现不如在训练数据上的表现。 过拟合的模型会“记住”训练数据集中的噪声和细节，从而对模型在新数据上的表现产生负面影响。

使用训练好的模型

最后，使用训练好2000轮的模型对测试集中的图像进行预测，并输出结果到csv文件。

读取测试集

方法同 读取训练集

```
16 model.load_weights(save_weights)

   directory_name = "test/test/"
   for i in range(18001, 23709):
       # print(filename) #just for test
       # img is used to store the image data
       # img = cv2.imread(directory_name + str(i) + ".jpg", cv2.IMREAD_GRAYSCALE)
       img = cv2.imread(directory_name + str(i) + ".jpg")
       img = img / 255.0
       img = cv2.resize(img, (image_size, image_size))
       array_of_img.append(img)
   test_images = np.array(array_of_img)
   del array_of_img
   # test_images = test_images.reshape(test_images.shape[0], image_size, image_size, 1)
   # test_images = test_images.astype('float32')
   # probability_model = tf.keras.Sequential([model,tf.keras.layers.Softmax()])
   # predictions = probability_model.predict(test_images)
```

测试集中有 5708 个图像。同样，每个图像都由 100x100 个像素表示，包含3个通道：

```
17 test_images.shape
```

```
17 (5708, 100, 100, 3)
```

```
18 model.load_weights(save_weights)
   predictions = model.predict(test_images)
   results = np.argmax(predictions, axis=1)
   submissions = pd.read_csv('test.csv')
   submissions['label'] = results
   submissions.to_csv('submission.csv', index=False)
```

检验预测结果

在上例中，模型预测了测试集中每个图像的标签。我们来看看第一个预测结果：

```
19 np.set_printoptions(suppress=True)
   predictions[0]
```

```
19 array([0.00002822, 0.99997175], dtype=float32)
```

预测结果是一个包含 2 个数字的数组。它们代表模型对 2 种不同性别中每种性别的“置信度”。您可以看到哪个标签的置信度值最大：

```
20 gender = np.argmax(predictions[0])
```

因此，该模型非常确信这个图像是女性，或 `class_names[1]`。

```
21 class_names[gender]
```

```
21 'female'
```

最后，我们随机显示对25张图片的预测。

即使模型最终的精度达到了**0.92782**，也会有预测错误的情况。

```
22 plt.figure(figsize=(10,10))
   for i in range(25):
       plt.subplot(5,5,i+1)
       plt.xticks([])
       plt.yticks([])
       plt.grid(False)
       sample = random.randint(0, 5707)
       plt.imshow(test_images[sample][:,:,::-1])
       plt.xlabel(class_names[results[sample]])
   plt.show()
```